L'ÈRE DU RISQUE INVISIBLE

IA + ARME BIOLOGIQUE

Analyse de risque et stratégies de défense (2023-2026). Convergence entre modèles de langage et synthèse biologique.

STATUS: UNCLASSIFIED // RESEARCH ONLY

DATE: OCTOBRE 2026
PREPARED BY: MANUS ANALYTICS

01. Poser le cadre : Dual-use, DURC et IA-biologie

DÉFINITIONS CLÉS

Dual-use (Double usage)
Technologie bénéfique (médecine, climat) pouvant être détournée pour causer un dommage.

DURC
Recherche dont le mésusage a des conséquences critiques pour la santé ou la sécurité nationale.

PRINCIPES DE DÉFENSE

Évaluation
Analyser la plausibilité et la gravité du mésusage avant déploiement.

Supervision
Maintenir un contrôle humain sur les capacités à haut impact.

Traçabilité
Assurer la transparence des accès et des usages critiques.

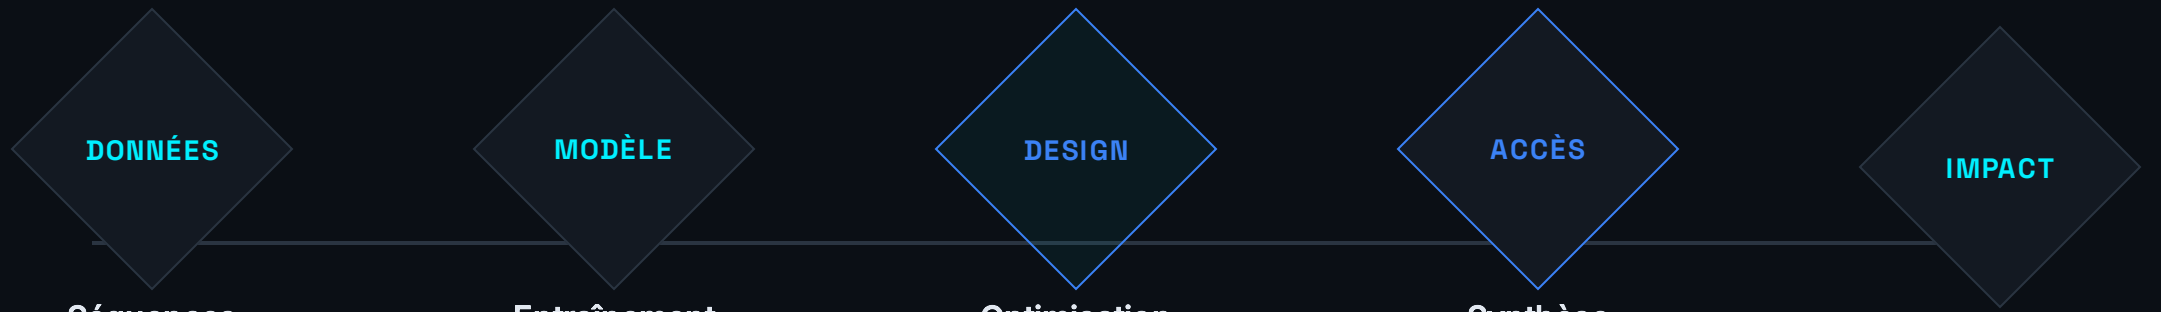
PHILOSOPHIE

La gouvernance ne vise pas à interdire le progrès, mais à proportionner la vigilance au risque potentiel.

> *Approche holistique : l'IA agit comme un multiplicateur de capacités sur une infrastructure physique préexistante.*

SOURCES: OMS (2020), CSR (2025), PLoS Comp Bio (2025)

02. Où se situe le risque : De la donnée au monde réel



Fait établi

Un modèle performant ne garantit ni la validité biologique ni l'accès aux matériaux physiques nécessaires.

Extrapolation

L'IA pourrait réduire le "coût cognitif" de certaines étapes de planification, sans pour autant automatiser l'attaque.

SOURCES: National Academies (2025), RAND (2025)

03. Urbina 2022 : Preuve computationnelle, pas arme validée

> "En inversant l'objectif d'une IA de découverte de médicaments pour favoriser la toxicité, nous avons généré des molécules virtuelles préoccupantes."
>
> **— Urbina et al., Nature Machine Intelligence**

40,000

SORTIES VIRTUELLES CANDIDATES

< 6H

TEMPS DE GÉNÉRATION SUR SERVEUR

//RÉSERVES MÉTHODOLOGIQUES IMPORTANTES

Aucune molécule n'a été synthétisée ou testée physiquement. La synthétisabilité et l'activité biologique réelle n'ont pas été démontrées. Il s'agit d'une preuve de concept informatique, pas d'une arme opérationnelle.

SOURCES: Urbina et al. (2022), Nature Machine Intelligence

04. Ce que les preuves techniques permettent de conclure

FAITS ÉTABLIS	EXTRAPOLATIONS / RÉSERVES
✔ L'IA peut générer des milliers de structures moléculaires toxiques prédites en quelques heures.	! *L'IA "crée" des armes biologiques. (La synthèse et la validation restent manuelles et complexes).*
✔ Les modèles actuels abaissent les barrières d'accès à l'information biologique critique.	! *L'IA automatise une attaque. (L'intention humaine et la logistique physique sont les goulots d'étranglement).*
✔ Le screening ADN industriel peut détecter des séquences pathogènes connues.	! *Le screening est infaillible. (Les menaces "de novo" ou modifiées peuvent contourner les filtres basés sur l'homologie).*

SOURCES: RAND (2025), International AI Safety Report (2025)

05. Évaluer les LLM sans confondre information et capacité

ÉTUDE OPENAI/GRYPHON (2024)

Impact sur la productivité experte

Les hausses de performance des experts assistés par LLM **ne sont pas statistiquement significatives** sur les tâches complexes de création de menaces biologiques.

CONCLUSION RAND (2024)

Écart de planification

Pas de différence majeure entre les plans d'attaque avec ou sans LLM. Les modèles reflètent principalement **l'information déjà disponible en ligne**, structurée mais non augmentée.

GARDE-FOUS OPÉRATIONNELS

Protocoles de validation

Nécessité de **red-teaming indépendant** et d'évaluations rigoureuses pré-déploiement pour détecter des capacités émergentes imprévues.

SYNTHÈSE ANALYTIQUE

Information vs Autonomie

Le risque réside dans l'accélération de la recherche documentaire plutôt que dans l'invention de nouvelles menaces. L'autonomie biologique totale des LLM demeure **non démontrée**.

SOURCES: OpenAI (Jan 2024), RAND (Jan 2024), NTI (2024)

06. Gouverner les Biological Design Tools

EV

ÉVALUATION

- Red-teaming indépendant pré-déploiement.
- Benchmarks de capacités à haut impact.
- Réévaluation continue des modèles.

AC

ACCÈS & CONTRÔLE

- Accès gradué selon la sensibilité.
- Journalisation et audit des requêtes.
- Filtrage des sorties dangereuses.

SH

SUPERVISION HUMAINE

- Intervention humaine sur les étapes critiques.
- Gouvernance des données d'entraînement.
- Responsabilité légale des développeurs.

MR

MONITORING & RÉPONSE

- Surveillance des interfaces numérique-physique.
- Partage sécurisé des alertes industrielles.
- Plans de réponse en cas de mésusage.

SOURCES: NTI (2024), PLOS Computational Biology (2025)

07. BioWatch, DARPA et le pré-symptomatique

// FAIT ÉTABLI

BioWatch (DHS)

Dispositif de biosurveillance environnementale et d'alerte précoce via collecte d'air en milieu urbain.

// R&D DARPA

Programmes convergents

"Friend or Foe" et "Convergence" axés sur la détection environnementale et les biosenseurs nouvelle génération.

// LIMITE ANALYTIQUE

Diagnostic humain

Les sources publiques ne démontrent pas de capacité de diagnostic pré-symptomatique humain validée pour ces systèmes.



SOURCES: National Academies (2014, 2025), DARPA (2023), DoD (2023)

08. Le bouclier ADN : Séquence, Client, Revue humaine

01 **Screening de Séquence**

Comparaison des commandes avec les bases de pathogènes connus (IGSC v3.0, 2024).

02 **Vérification du Client**

Validation de la légitimité institutionnelle et de l'usage prévu du matériel.

03 **Revue Experte**

Analyse humaine obligatoire pour toute alerte ou séquence ambiguë.

STATUT DE GOUVERNANCE

IGSC

Norme industrielle volontaire couvrant la majorité de la capacité commerciale mondiale.

US Framework

Cadre OSTP 2024 (en révision suite au décret de mai 2025).

LACUNE : Risque résiduel pour les équipements de paillasse et les fournisseurs non-membres de l'IGSC.

SOURCES: IGSC (2024), OSTP (2024), HHS (2023)

09. Gouvernance 2023–2026 : Convergence normative

OCT. 2023

EXECUTIVE ORDER 14110

Cadre US sur la sécurité de l'IA et la biosecurity (révoqué en janv. 2025).

NOV. 2023

DÉCLARATION DE BLETCHLEY

Reconnaissance internationale des risques de l'IA de pointe.

MAI 2024

ENGAGEMENTS DE SÉOUL

Seuils de risque et protocoles d'évaluation volontaires.

2025-2026

VERS UN NOUVEAU CADRE

Révision des standards de screening et coopération globale accrue.

Conclusion : On observe une convergence vers des principes de sécurité partagés, mais l'absence d'un régime mondial contraignant demeure un défi pour la biodéfense.

SOURCES: Federal Register (2023), UK Gov (2023, 2024), White House (2025)

10. Iran et attribution : Maintenir les degrés de preuve

ODNI 2024

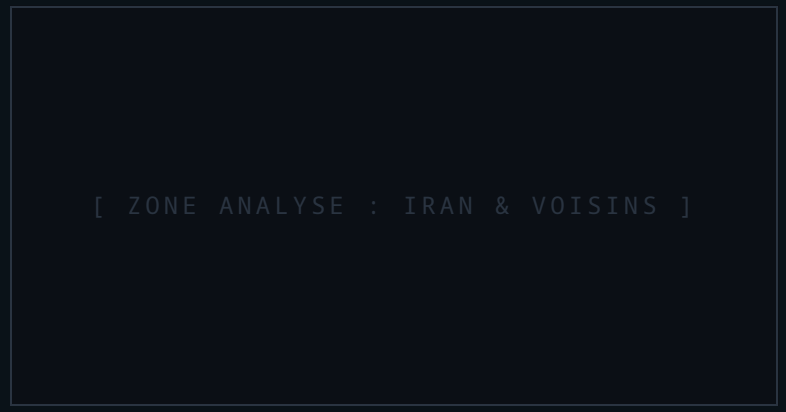
L'Iran poursuit probablement des activités de R&D aux fins offensives en chimie et biologie ; il s'agit d'une évaluation de renseignement fondée sur des sources classifiées, non d'une preuve publique détaillée.

CRS 2023

La convergence entre IA et biologie réduit les barrières techniques globales. L'Iran conserve des capacités duales (recherche civile et applications militaires) nécessitant une surveillance ciblée.

NOTE MÉTHODOLOGIQUE

Le rapport IISS pertinent date d'avril 2021 et porte principalement sur les vecteurs (missiles / UAV). Aucun rapport IISS 2023–2026 dédié spécifiquement au dual-use IA-bio n'a été identifié dans les sources ouvertes.



SOURCES: ODNI (2024), CRS (2023), IISS (2021)

11. Conclusion : Défense en profondeur + Bibliographie

PRAXIS DÉFENSIVE

Face à l'invisibilité du risque, la résilience repose sur la redondance des contrôles : évaluations indépendantes, screening industriel rigoureux et coopération internationale adaptative.

L'IA ne crée pas la menace *ex nihilo*, mais elle en modifie radicalement le coût d'accès cognitif. La réponse doit être systémique, liant sécurité numérique et contrôle physique.

RÉFÉRENCES MAJEURES

URBINA ET AL. (2022)
Nature Machine Intelligence | doi.org/10.1038/s42256-022-00465-9

NATIONAL ACADEMIES (2025)
Strategic Analysis | nationalacademies.org/read/28868

RAND BIORISK (2025)
Research Report | rand.org/pubs/RRA4087-1

IGSC PROTOCOL (2024)
Industrial Standards | genesynthesisconsortium.org/protocol